

# CLASSIFICAÇÃO

**Prof. Julio Cesar dos Reis**

**[jreis@ic.unicamp.br](mailto:jreis@ic.unicamp.br)**

**[www.ic.unicamp.br/~jreis](http://www.ic.unicamp.br/~jreis)**

# Vídeo

# Objetivos da aula

3

- Aprender terminologia e conceitos sobre a tarefa de classificação
- Estudar uma técnica básica para a classificação

# Classificação

5

- Objetiva a partir de um banco de dados contendo objetos pré-classificados (objetos cuja classe é conhecida), construir um modelo que seja capaz de **classificar automaticamente novos objetos** cuja a classe é desconhecida) em função de suas características
- O modelo criado (via treinamento) é chamado de modelo classificador

# Tarefa de classificação


6

- Cada exemplo pertence a uma classe pré-definida
- Cada exemplo consiste de
  - ▣ Um conjunto de atributos preditores
  - ▣ Um atributo classe
- Objetivo
  - ▣ Predizer a classe do exemplo dado seus valores de atributos preditores


# Exemplo 1 de classificação

7

Objetos da  
Classe A




Objetos da  
Classe B




# Exemplo 1 de classificação

8

Objetos da  
Classe A




Objetos da  
Classe B




**Existe um padrão?**

Pertence a qual classe?




Pertence a qual classe?




# Exemplo 1 de classificação

9

Objetos da  
Classe A



Objetos da  
Classe B





**Existe um padrão?**

barra esquerda maior  $\Rightarrow$  B



barra esquerda menor  $\Rightarrow$  A

Pertence a qual classe?



**B**

Pertence a qual classe?




**A**




# Exemplo 2 de classificação

10

Objetos da  
Classe A




Objetos da  
Classe B




# Exemplo 2 de classificação

11

Objetos da  
Classe A




Objetos da  
Classe B




**Existe um padrão?**

Pertence a qual classe?




Pertence a qual classe?




# Exemplo 2 de classificação

12

Objetos da  
Classe A



Objetos da  
Classe B





**Existe um padrão?**

barras de mesmo tamanho  $\Rightarrow$  A



barra de tamanho distinto  $\Rightarrow$  B

Pertence a qual classe?



**B**

Pertence a qual classe?




**A**


# Exemplo 3 de classificação

13

Objetos da  
Classe A




Objetos da  
Classe B




# Exemplo 3 de classificação

14

Objetos da  
Classe A




Objetos da  
Classe B



**Existe um padrão?**


Pertence a qual classe?




# Exemplo 3 de classificação

15

Objetos da  
Classe A



Objetos da  
Classe B



**Existe um padrão?**

se


o quadrado da soma das  
duas barras for menor ou igual a 100

$$(a + b)^2 \leq 100$$

$\Rightarrow$  A

Senão  $\Rightarrow$  B

Pertence a qual classe?



# Exemplo de classificação\*

16

- Uma editora internacional publica o livro “Guia de Restaurantes Franceses na Inglaterra” em 3 países: Inglaterra, França e Alemanha
- A editora tem um banco de dados sobre clientes nesses 3 países
- Deseja-se saber quais clientes são mais prováveis compradores do livro (para fins de mala direta direcionada)
  - ▣ Atributo meta (classe): compra (sim/não)

# Exemplo de classificação

17


Sexo	País	Idade	Compra
M	França	25	Sim
M	Inglaterra	21	Sim
F	França	23	Sim
F	Inglaterra	34	Sim
F	França	30	Não
M	Alemanha	21	Não
M	Alemanha	20	Não
F	Alemanha	18	Não
F	França	34	Não
M	França	55	Não



# Modelo de classificação

18

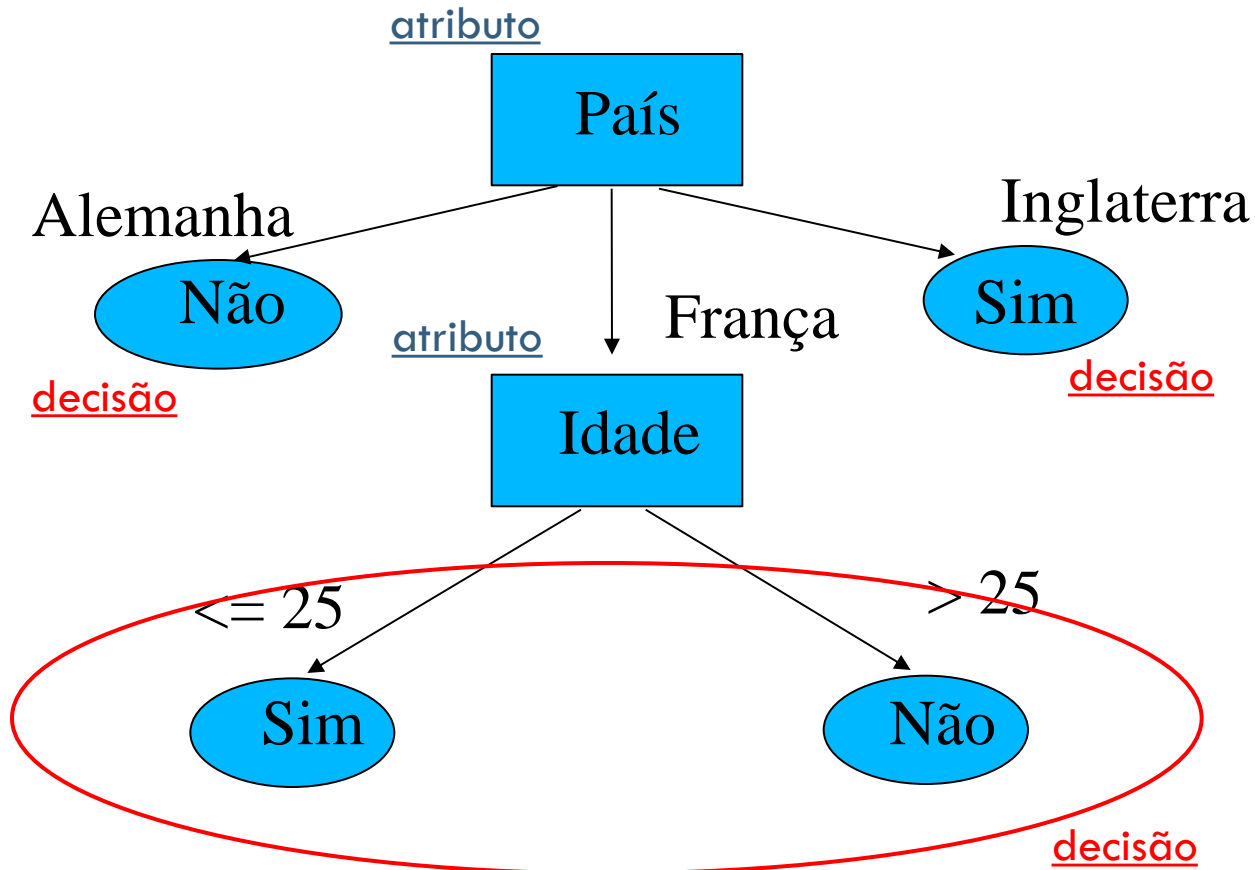
## □ Árvore de decisão



# Modelo de classificação

19

## □ Árvore de decisão



# Terminologia

20

- Exemplo, um objeto, um caso, um registro, uma tupla
- Atributo, variável, *feature*, característica
- **Conjunto de treinamento (aprendizado)**
- **Conjunto de teste (avaliação)**

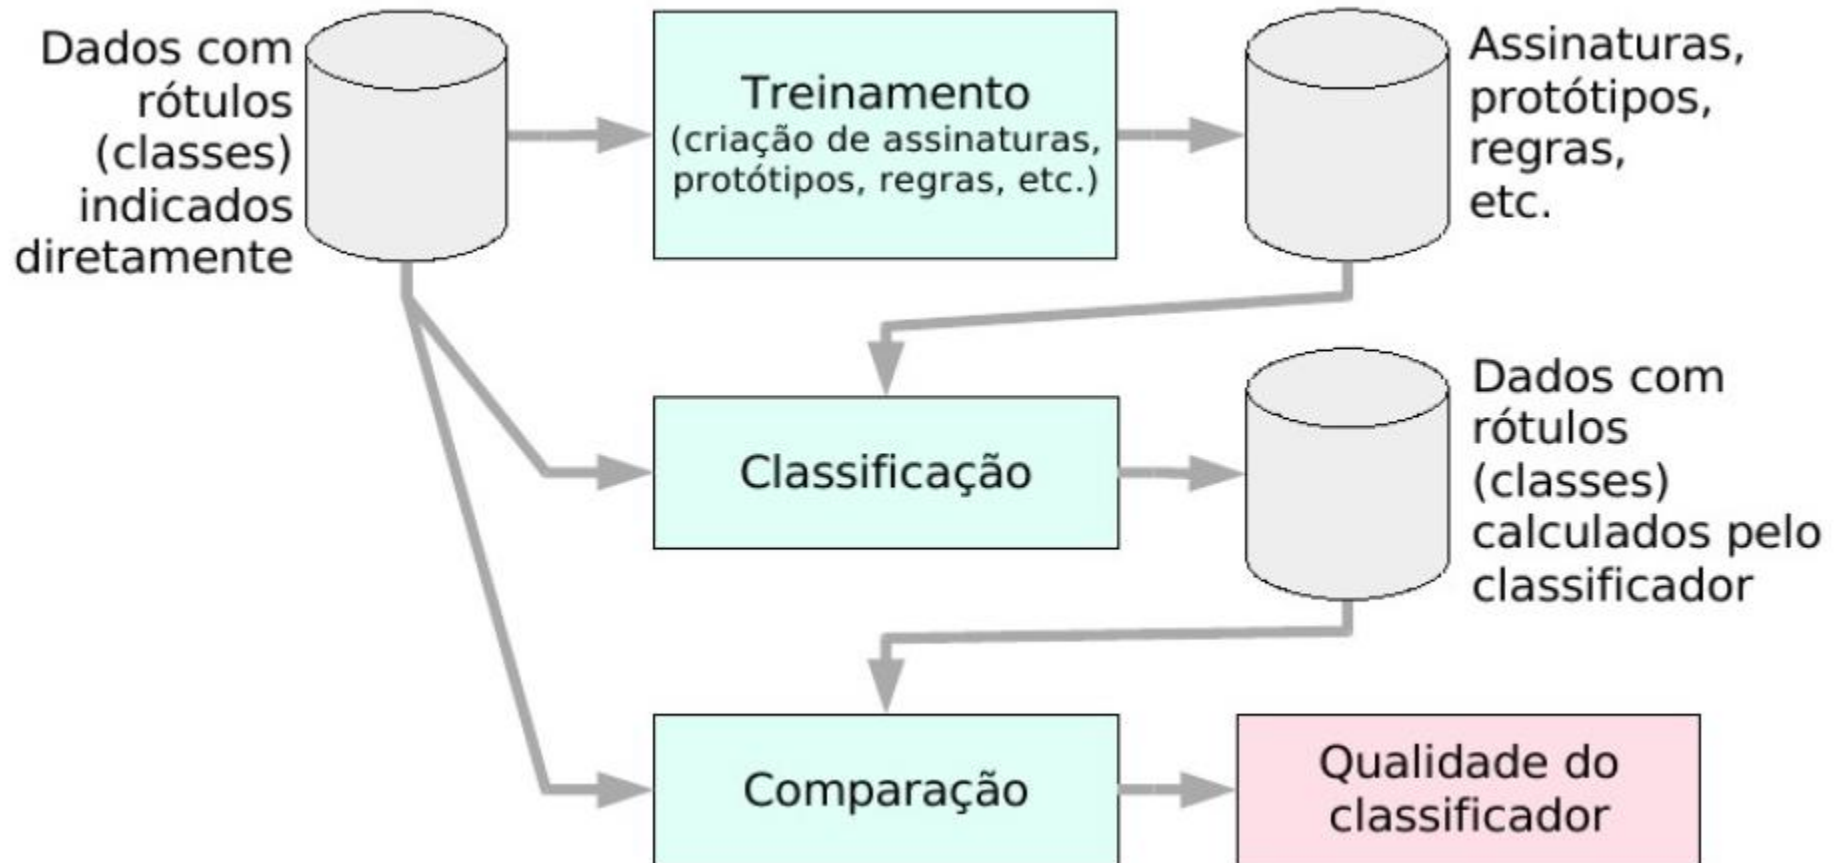
# Fases na classificação

21

- **Predição de uma categoria ou classe discreta**
- Primeira fase
  - ▣ Entrada: Instancias para as quais as classes são conhecidas
  - ▣ Cria-se um **classificador** ou **modelo** (fase de treinamento)
- Segunda fase
  - ▣ Entrada: vários dados para os quais as classes não são conhecidas
  - ▣ Usa-se o classificador para indicar classes para esses dados
  - ▣ Podemos avaliar o modelo classificando instancias com classes conhecidas


# Fases na classificação

22



# Uso do classificador


23



# Hipóteses de classificação


24

## Exemplo dos cogumelos comestíveis e venenosos



# Problema da classificação



25







# Classificação e espaço de atributos

26





# Classificação e espaço de atributos

27



# Classificação e espaço de atributos

28



# Hipótese do aprendizado indutivo

30

- A tarefa de classificação é não determinística
- Qualquer hipótese que aproxime bem o conceito alvo num conjunto de treinamento, suficientemente grande, aproximará o conceito alvo para exemplos não observados

# Métodos de classificação supervisionada

32

- **Baseado em separabilidade (entropia)**
  - Árvores de decisão
  
- **Baseados em distância e diferenças**
  - Mínima distância euclidiana e variantes
  
- **Baseado nos dados vizinhos**
  - Algoritmo dos vizinhos mais próximos e similares (KNN)
  
- **Baseado em particionamento**
  - Redes neurais
  - SVM (*support vector machines*)

# Árvores de decisão


# Exemplo de classificação

42

Sexo	País	Idade	Compra
M	França	25	Sim
M	Inglaterra	21	Sim
F	França	23	Sim
F	Inglaterra	34	Sim
F	França	30	Não
M	Alemanha	21	Não
M	Alemanha	20	Não
F	Alemanha	18	Não
F	França	34	Não
M	França	55	Não

# Árvores de decisão (AD)


43





# Árvores de decisão

44



# Árvores de decisão

45

- Um dos métodos práticos mais usados
- Induz funções discretas
  - ▣ Robustas a ruído
- Capaz de aprender expressões disjuntivas
  - Se país = Inglaterra
  - OU**
  - Se país = França e idade  $\leq 25$
  - Então
  - Comprar = sim

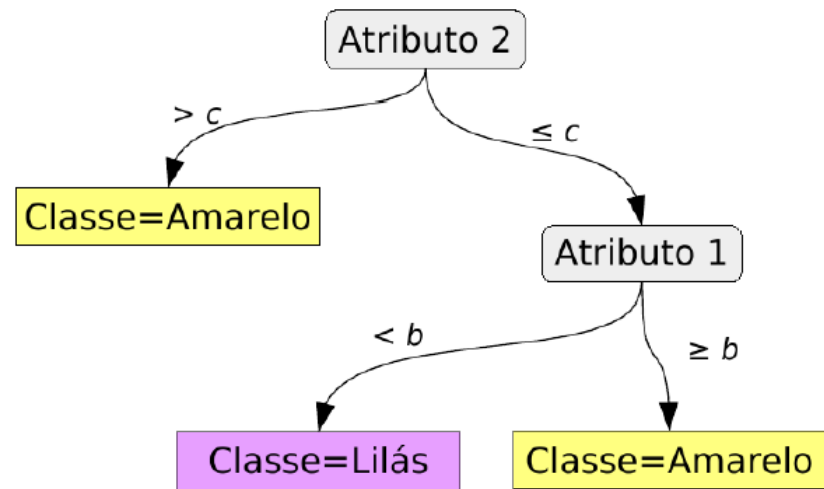

# Árvores de decisão

46

- Classificação tem como base um conjunto de atributos
- Cada nó interno corresponde a um teste sobre os valores dos atributos
- Os arcos são rotulados com os valores possíveis do teste
- Cada folha na árvore especifica a classificação


# Árvores de decisão

47



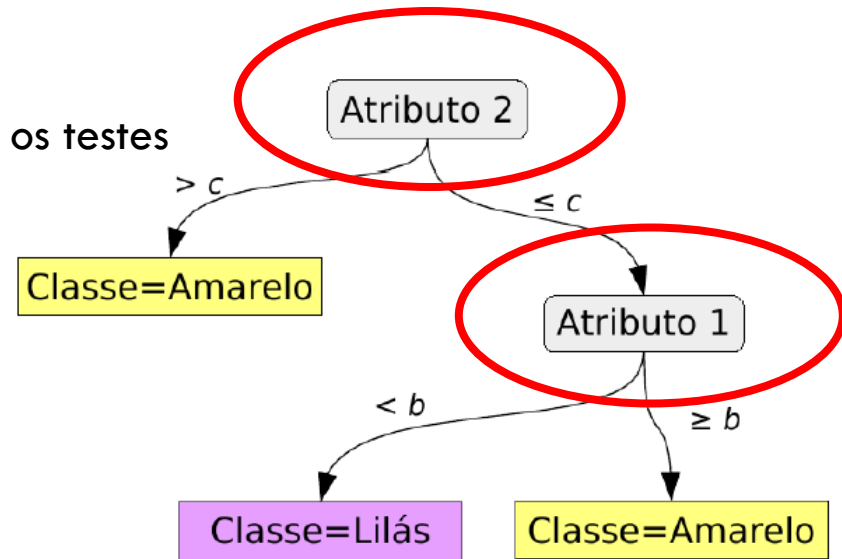
# Árvores de decisão

48



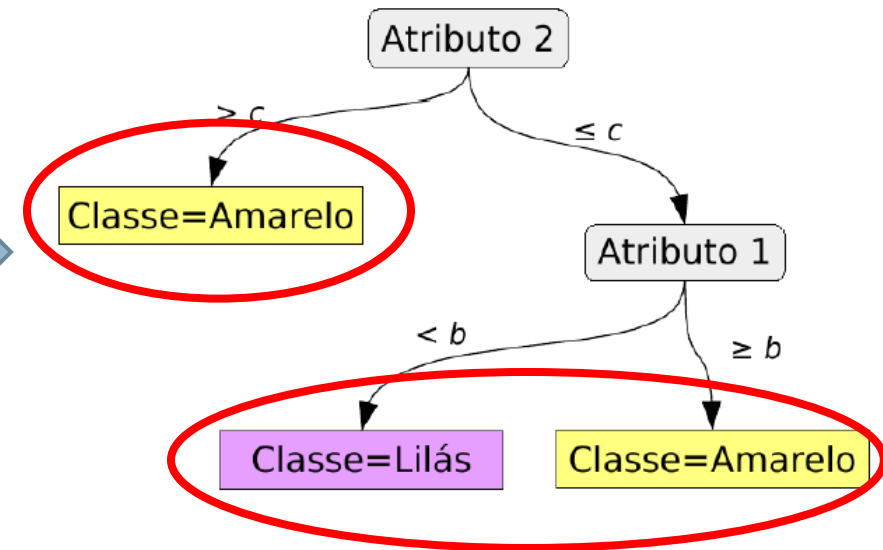

Arcos: valores sobre os testes

Nós: teste sobre atributos



# Árvores de decisão

49



Folhas: classes determinadas no conjunto


# Exemplo do restaurante

50

- Espera por uma mesa num restaurante?
  - ▣ Decidir que propriedades (ou atributos) estão disponíveis para descrever os exemplos do domínio
- Alternativas
  - ▣ Existe um bar no local?
  - ▣ Qual o “tamanho” da fome?
  - ▣ Restaurante está cheio?
  - ▣ Qual o tempo de espera?
  - ▣ Qual o nível de sua paciência hoje?

# Esperar por uma mesa?

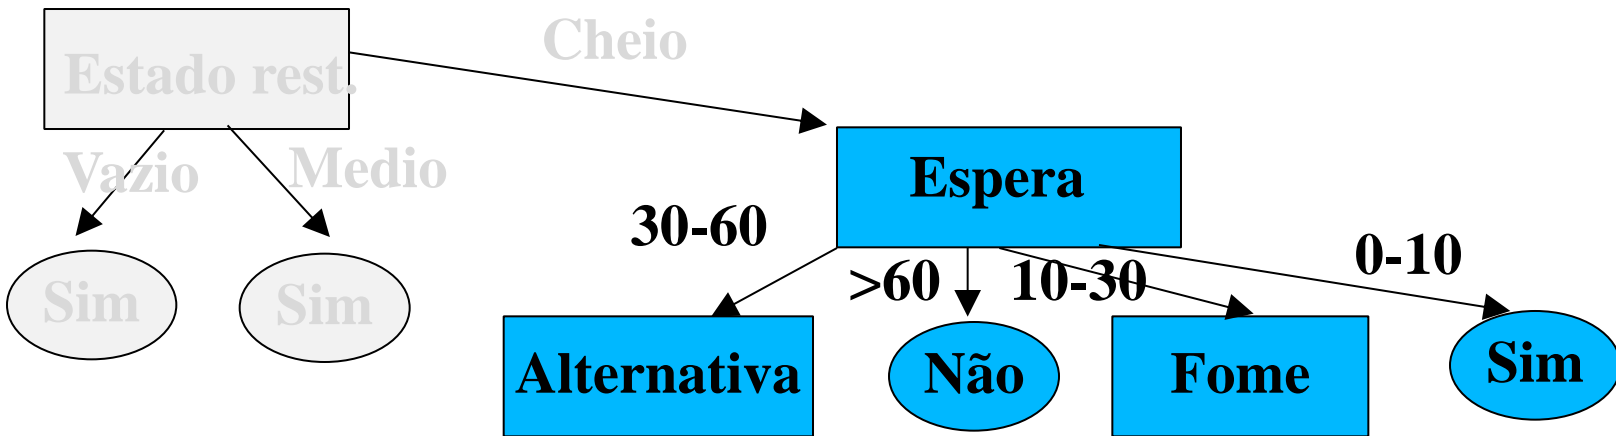
51





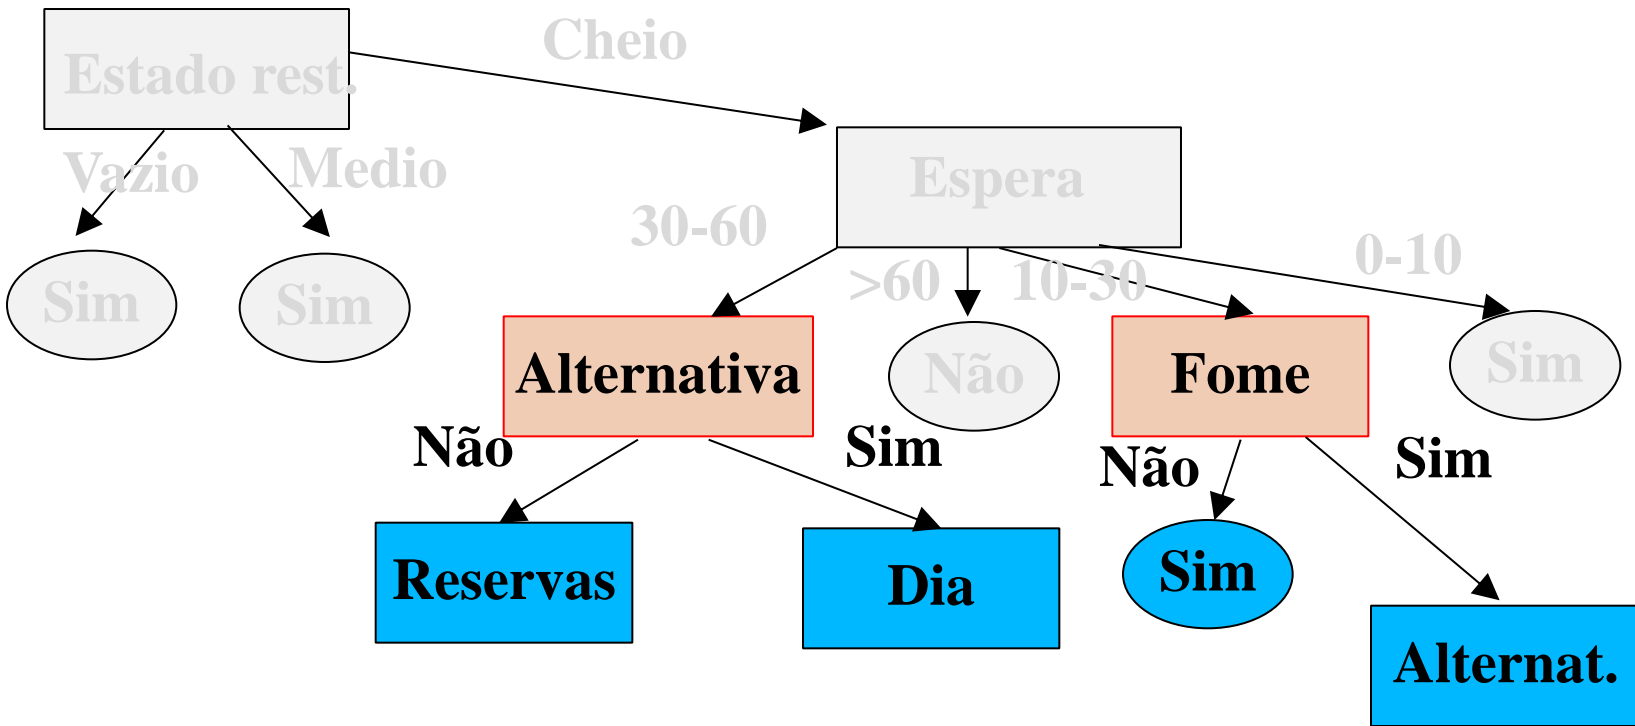
# Esperar por uma mesa?

52



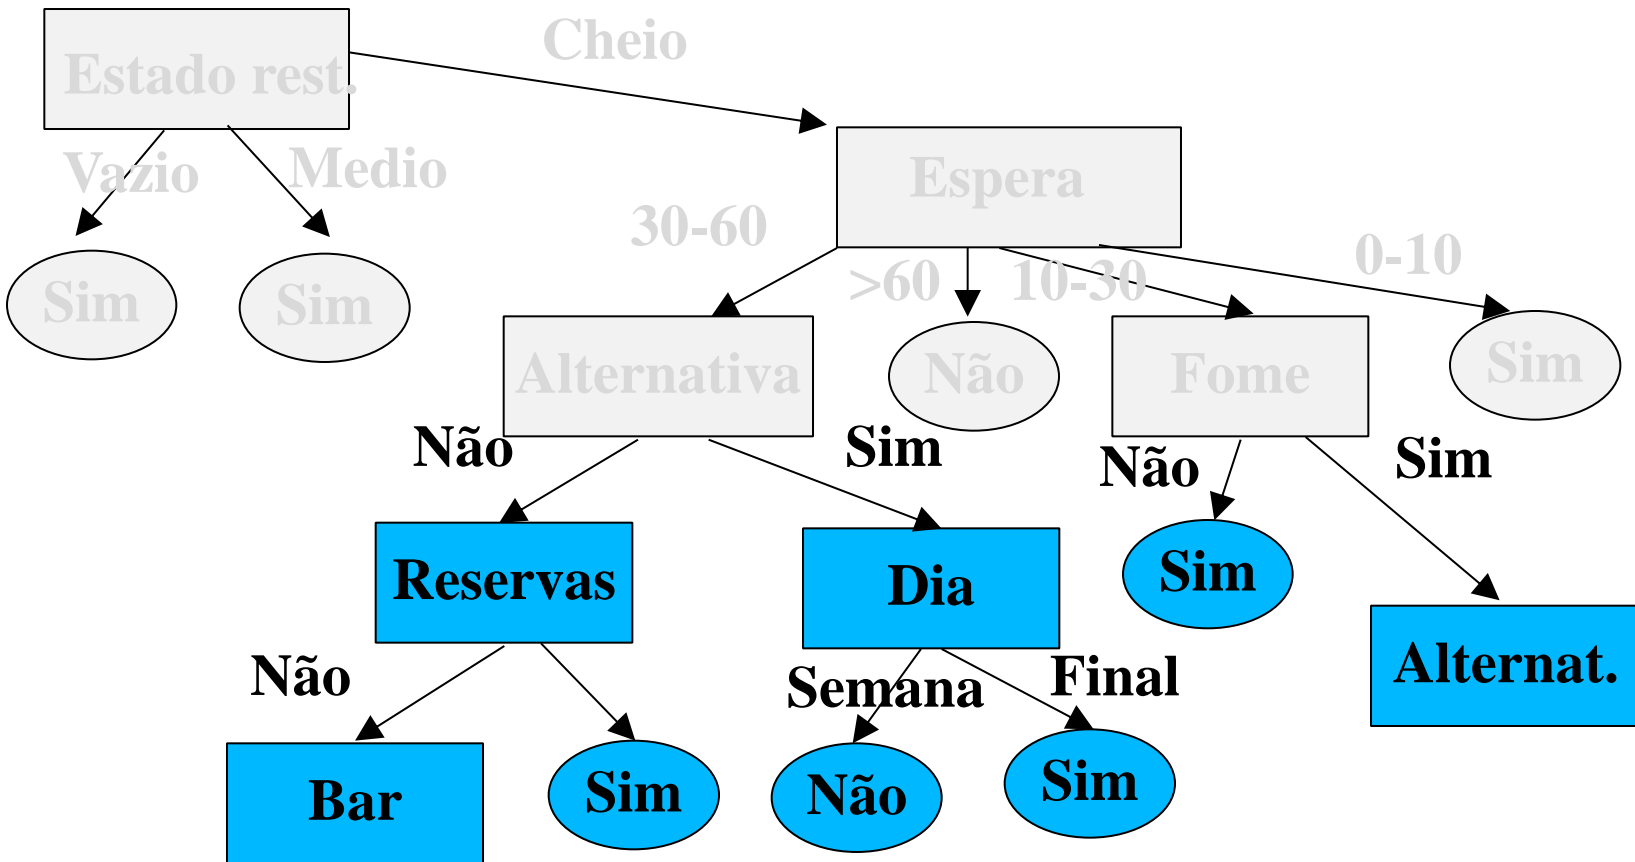
# Esperar por uma mesa?

53



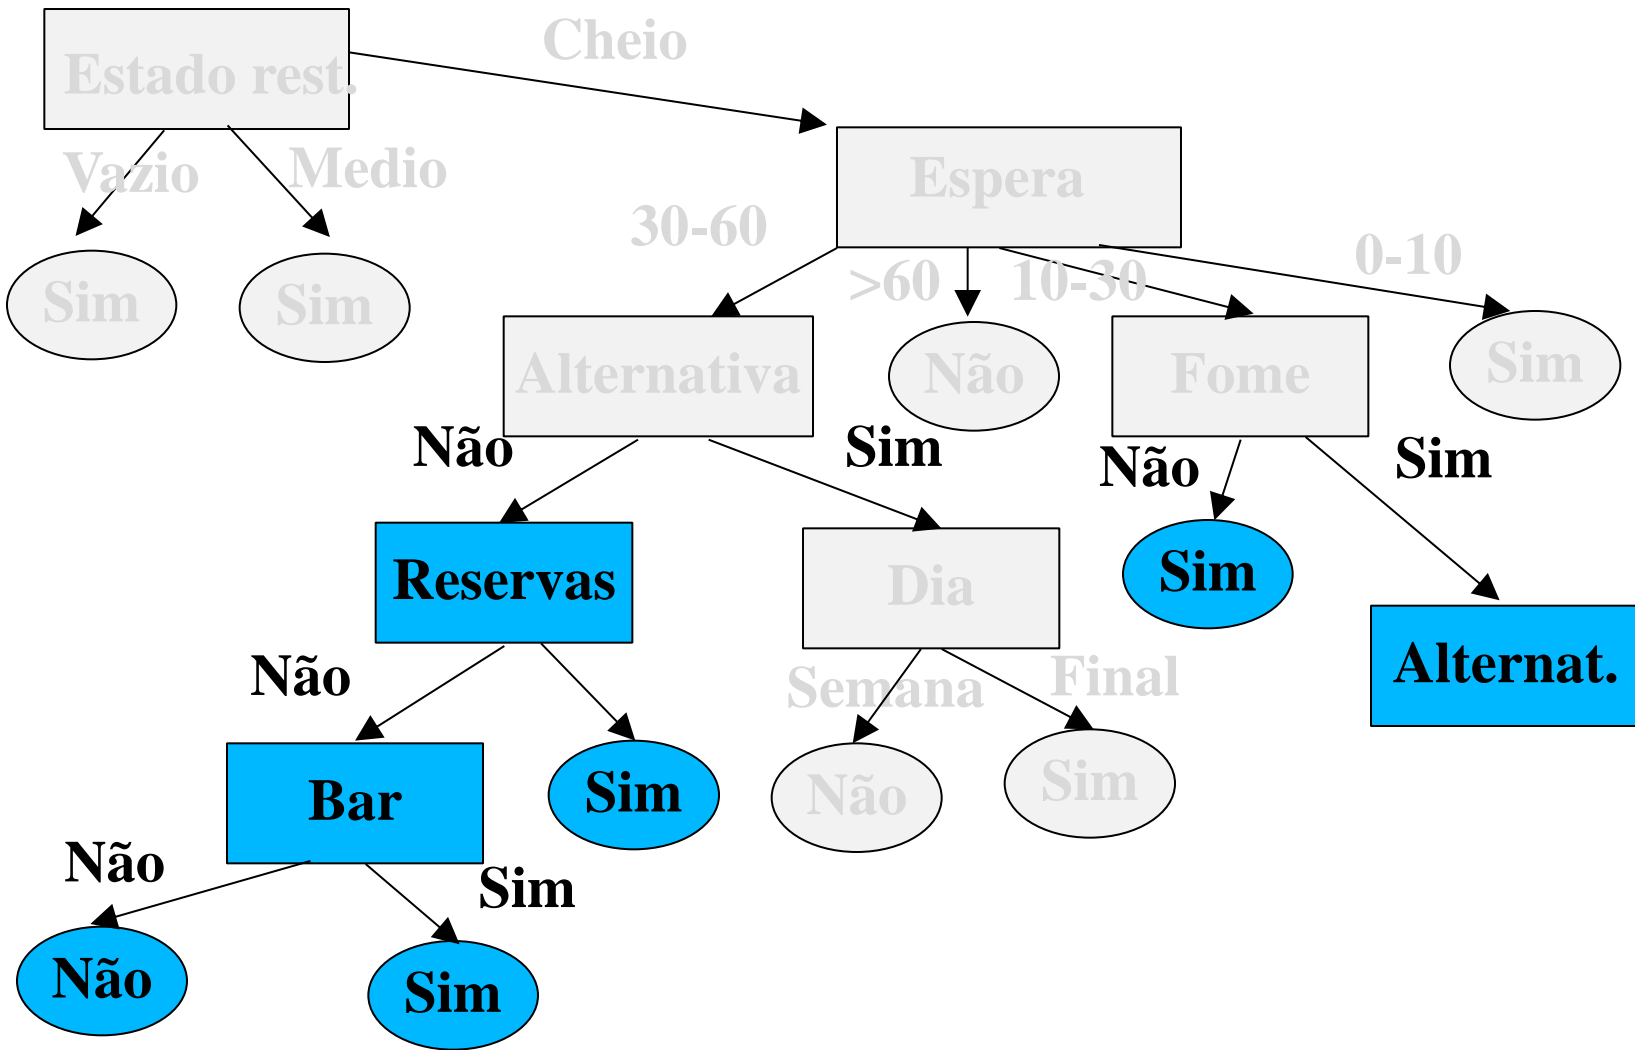
# Esperar por uma mesa?

54



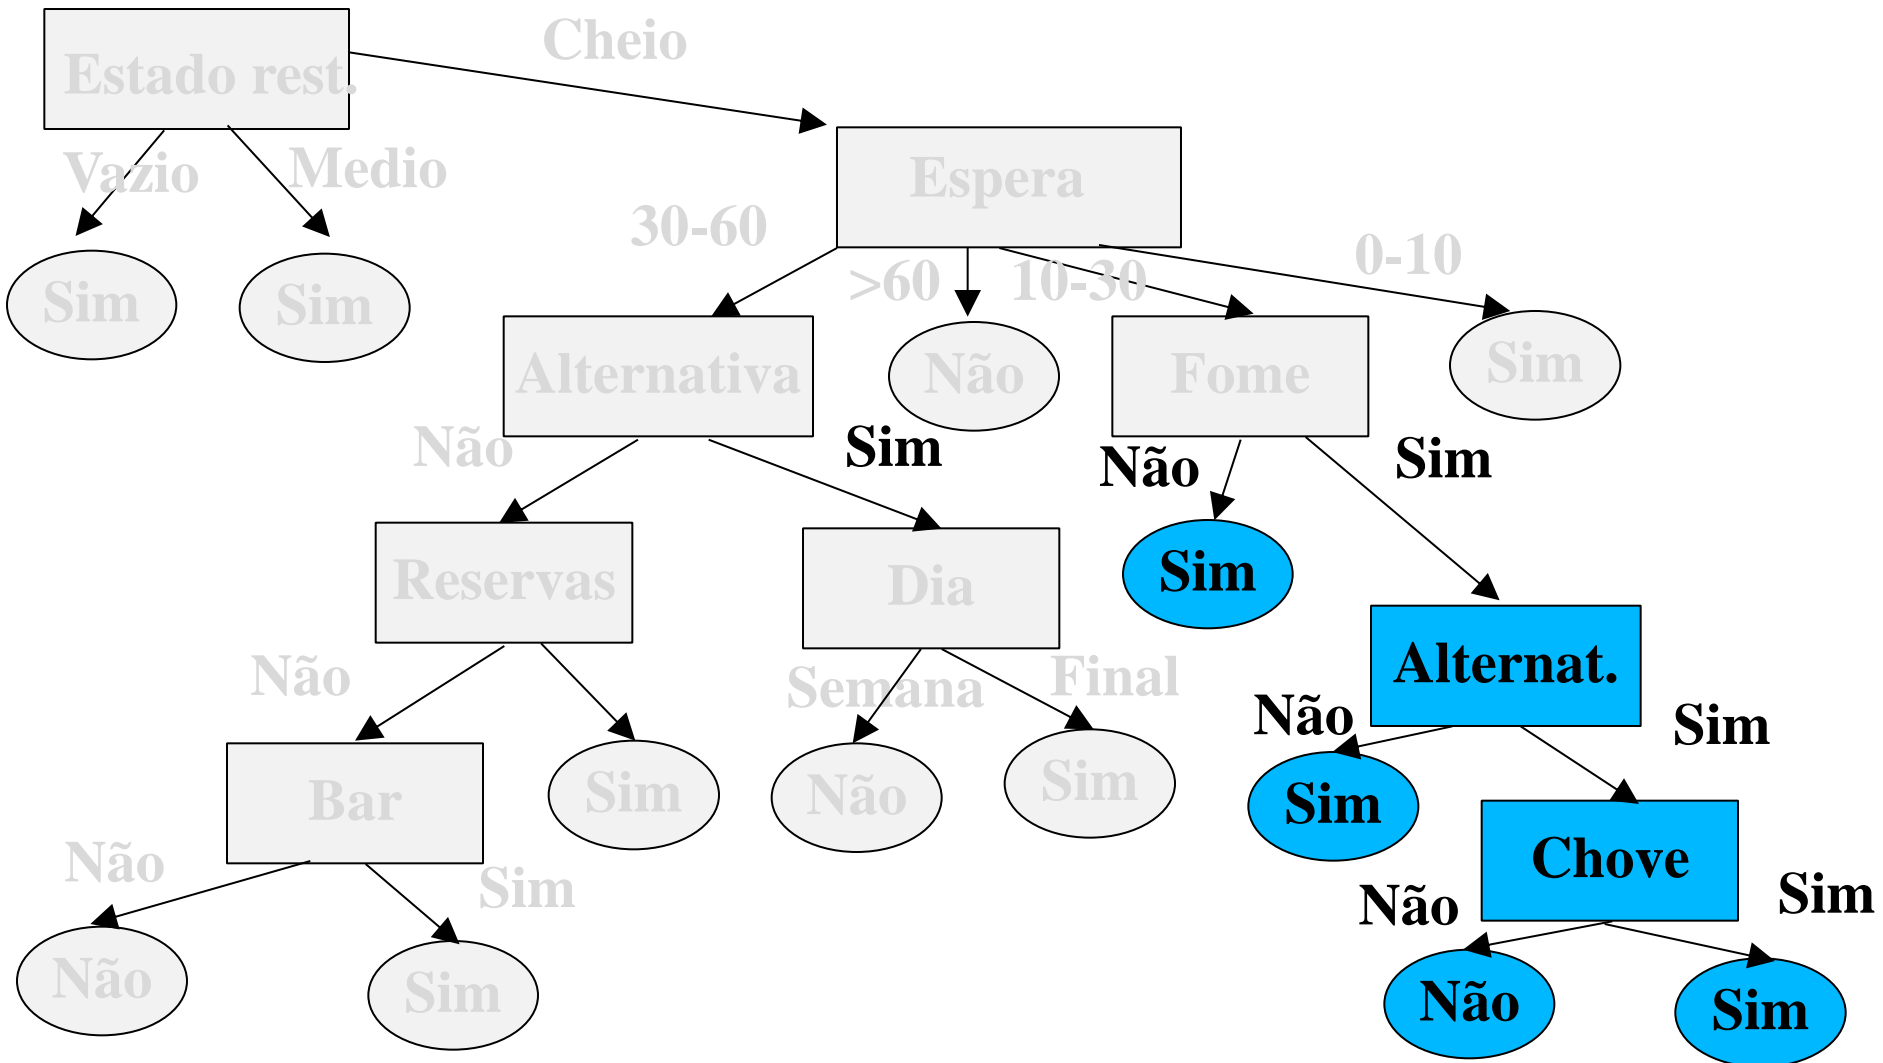
# Esperar por uma mesa?

55



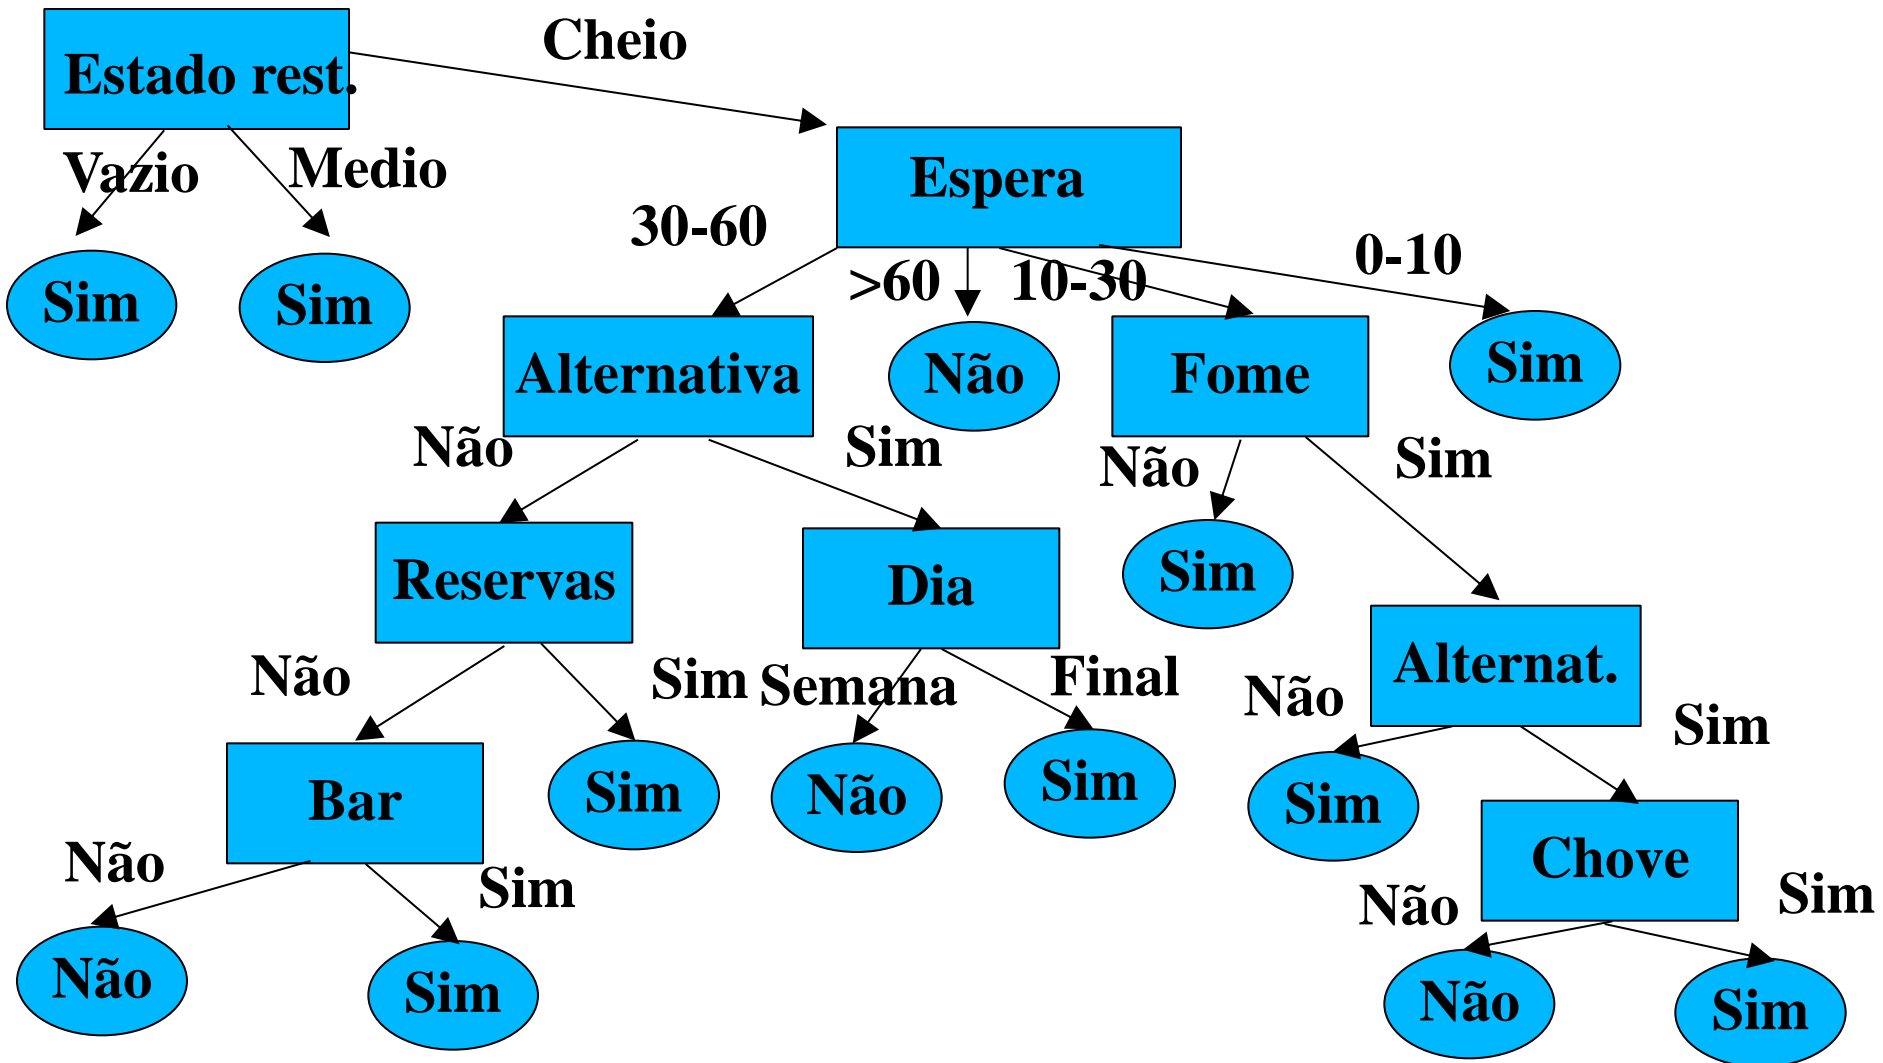
# Esperar por uma mesa?

56



# Esperar por uma mesa?

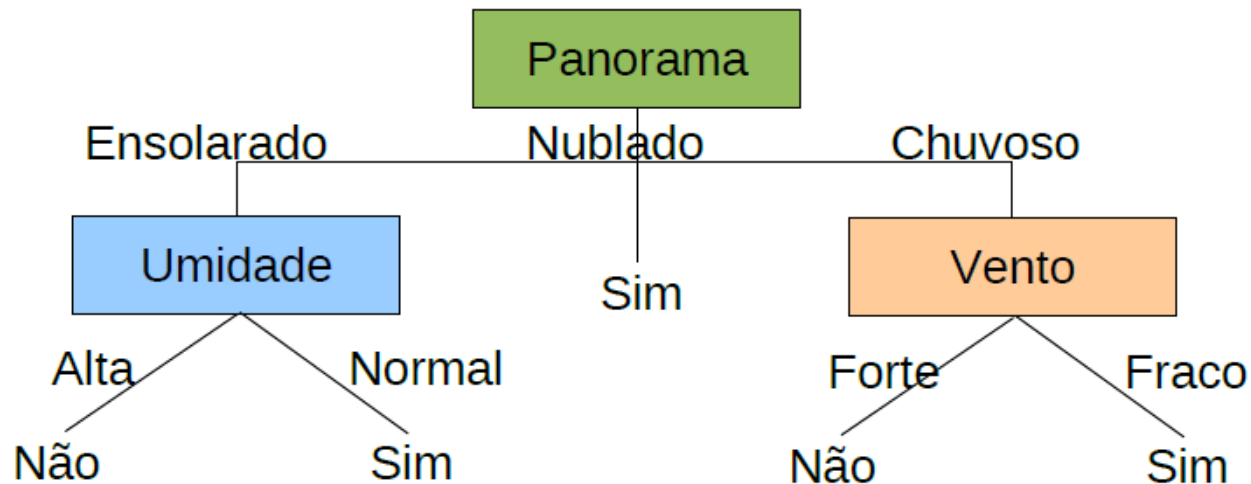
57



# Tomada de decisões

58

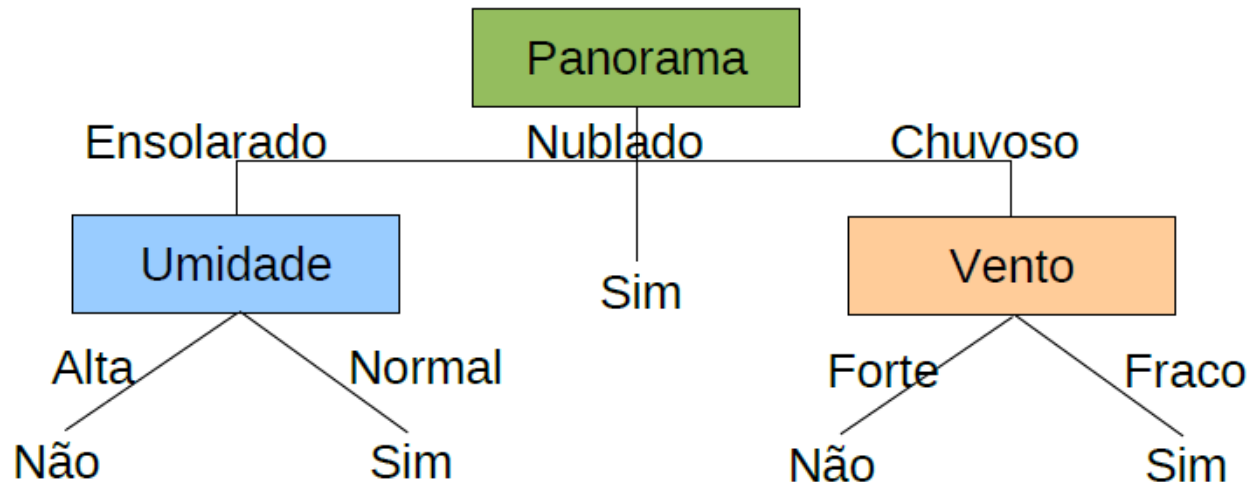
- Tomada de decisão para o problema “jogar tênis”
  - ▣ Classificar se condições de um dia são adequadas ou não para se jogar tênis



# Tomada de decisões

59

- Tomada de decisão para o problema “jogar tênis”
  - ▣ Classificar se condições de um dia são adequadas ou não para se jogar tênis



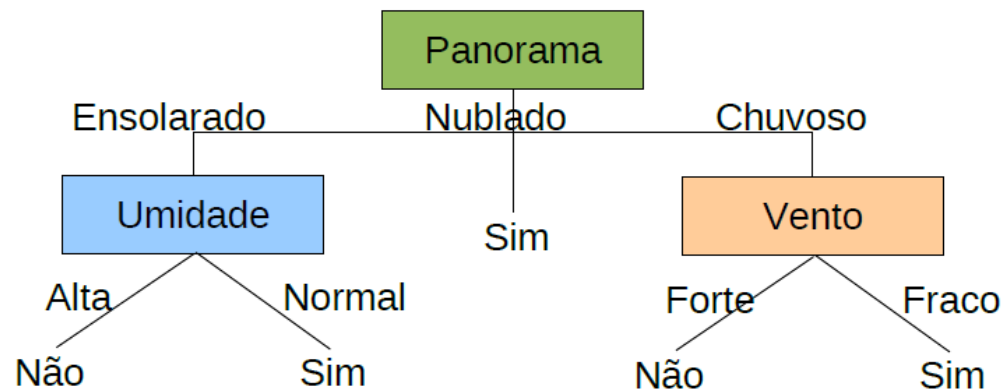
- ▣ Instância: <Panorama=Ensolarado, Temperatura=Quente, Umidade=Alta>
- ▣ Saída: Não



# Tomada de decisões

60

- Pode-se montar uma expressão para verificar quando é possível jogar tênis:



<Panorama=Ensolarado AND Umidade=Normal>

OR <Panorama=Nublado>

OR <Panorama=Chuvoso AND Vento=Fraco>

# Problemas apropriados para AD

61

- Instâncias são representadas por pares atributo-valor
  - ▣ Há um conjunto fixo de atributos (ex: Umidade) e seus valores (ex: Alta, Normal)
  - ▣ Situação ideal é quando cada atributo pode assumir poucos valores, no entanto, as árvores de decisão também podem trabalhar com valores reais

# Problemas apropriados para AD

62

- Instâncias são representadas por pares atributo-valor
  - ▣ Há um conjunto fixo de atributos (ex: Umidade) e seus valores (ex: Alta, Normal)
  - ▣ Situação ideal é quando cada atributo pode assumir poucos valores, no entanto, as árvores de decisão também podem trabalhar com valores reais
- A função a ser aproximada tem valores discretos
  - ▣ No exemplo a função deve produzir “Sim” ou “Não”
  - ▣ Pode-se facilmente estendê-las para produzir mais de dois valores de saída
  - ▣ Tornam-se mais complexas e menos utilizadas abordagens que buscam produzir valores reais como saída

# Criação da árvore

65

- Um exemplo é descrito pelo valor dos atributos e o valor do predicado objetivo (classificação)
- Solução trivial
  - ▣ Uma folha para cada exemplo
- Memorização das observações sem extrair padrão
- Extrair padrões significa descrever um grande número de casos de uma maneira concisa



# Criação com “força bruta”

66

## □ Tabela de decisão


Curso	Esporte	Tipo de comida
computação	futebol	japonesa
computação	natação	fastfood
computação	natação	fastfood
computação	natação	fastfood
matemática	voleibol	italiana
matemática	natação	vegetariana
matemática	voleibol	fastfood
biologia	futebol	fastfood
biologia	futebol	italiana
biologia	futebol	vegetariana
biologia	futebol	italiana
biologia	natação	fastfood

esporte




esporte	Voleibol		Italiana Fastfood	
	Natação	Fastfood Fastfood Fastfood	Vegetariana	Fastfood
	Futebol	Japonesa		Fastfood Italiana Vegetariana Italiana
		Computação	Matemática	Biologia

curso



consequente



# Criação com “força bruta”

67

- Desvantagem principal é o número de combinações
  - ▣ 3 cursos, 3 esportes: 9 células
  - ▣ 8 cursos, 6 esportes, 4 preferências musicais, 3 referências por filmes: **576 células em quatro dimensões**
- ▣ Mistura de consequentes
  - Como tratar?

# Indução de árvores

68

- Encontrar a árvore de decisão menor é um problema intratável
- Solução
  - ▣ Heurísticas simples criam boas árvores
  - ▣ Classificação correta com o menor número de teste

# Indução de árvores

69

- Encontrar a árvore de decisão menor é um problema intratável
- Solução
  - ▣ Heurísticas simples criam boas árvores
  - ▣ Classificação correta com o menor número de teste
- **Ideia básica**
  - ▣ Testar o atributo mais importante primeiro
  - ▣ Separar o maior número de casos, a cada vez



# Algoritmo para criação da árvore

70

- Uma árvore de decisão é construída de forma “*top-down*” usando o princípio de dividir-para-conquistar
- Inicialmente, todas as tuplas (registros) são alocadas na raiz da árvore
- Seleciona-se um atributo e divide o conjunto de tuplas
  - ▣ Objetivo: separar as classes
- Esse processo é repetido recursivamente

# Algoritmo ID3

71

- Considere um conjunto de dados para treinamento
- Constrói a árvore em uma abordagem *top-down* considerando a questão:
  - ▣ “Qual atributo é o mais importante e, portanto, deve ser colocado na raíz da árvore?”
- Cada atributo é testado e sua capacidade para se tornar nó raíz é avaliada
  - ▣ Seleção via métrica de **ganho de informação** do atributo

# Algoritmo ID3

72

- Cria-se tantos nós filhos da raíz quantos valores possíveis esse atributo puder assumir (caso discreto)
- Repete-se o processo *recursivamente* para cada nó filho da raíz
- Algoritmo para quando todas os atributos foram testados

# Ganho de informação no ID3

75

- Mede a efetividade de um atributo em classificar um conjunto de treinamento
  - ▣ Quão bom um atributo é para classificar um conjunto de treinamento
- Ganho de Informação de um atributo A:
  - ▣ É a redução na **Entropia**, causada pelo particionamento de exemplos de acordo com este atributo

$$\text{GI}(S, A) = E(S) - \sum_{v \in \text{Valores}(A)} \frac{S_v}{S} E(S_v)$$

# ○ problema “jogar tênis”

76

INSTÂNCIAS					CLASSE
Dia	Perspectiva	Temperatura	Umidade	Vento	JogarTênis
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Moderada	Alta	Fraco	Sim
D5	Chuvoso	Fresca	Normal	Fraco	Sim
D6	Chuvoso	Fresca	Normal	Forte	Não
D7	Nublado	Fresca	Normal	Forte	Sim
D8	Ensolarado	Moderada	Alta	Fraco	Não
D9	Ensolarado	Fresca	Normal	Fraco	Sim
D10	Chuvoso	Moderada	Normal	Fraco	Sim
D11	Ensolarado	Moderada	Normal	Forte	Sim
D12	Nublado	Moderada	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Moderada	Alta	Forte	Não

# Calculando ganho de informação

77

- Considere  $S$  um conjunto de treinamento contendo o atributo **Vento (Fraco ou Forte)**
  - ▣  $S$  contém 14 exemplos  $[9+, 5-]$  com relação a classe
- Considere:
  - ▣ Vento=Fraco (8 no total)
    - 6 exemplos positivos e 2 exemplos dos negativos
  - ▣ Vento=Forte (6 no total)
    - 3 exemplos positivos e 3 negativos

$$S = [9+, 5-]$$

$$S_{fraco} \leftarrow [6+, 2-]$$

$$S_{forte} \leftarrow [3+, 3-]$$

# Calculando ganho de informação

78

$$S = [9+, 5-]$$

$$S_{fraco} \leftarrow [6+, 2-]$$

$$S_{forte} \leftarrow [3+, 3-]$$

$$\mathbf{GI}(S, A) = E(S) - \sum_{v \in \mathbf{Valores}(A)} \frac{S_v}{S} E(S_v)$$



$$\mathbf{GI}(S, A) = 0.94 - \frac{8}{14} E(S_{fraco}) - \frac{6}{14} E(S_{forte})$$



$$\mathbf{GI}(S, A) = 0.94 - \frac{8}{14} 0.811 - \frac{6}{14} 1.00 = 0.048$$

$$E(S) = -p_{\oplus} \log_2 p_{\oplus} - p_{\ominus} \log_2 p_{\ominus}$$

# AD do problema “jogar tênis”

79

- Escolher a raiz (calculo de ganho de informação)

$$GI(S, \text{Panorama}) = 0.246$$

$$GI(S, \text{Umidade}) = 0.151$$

$$GI(S, \text{Vento}) = 0.048$$

$$GI(S, \text{Temperatura}) = 0.029$$

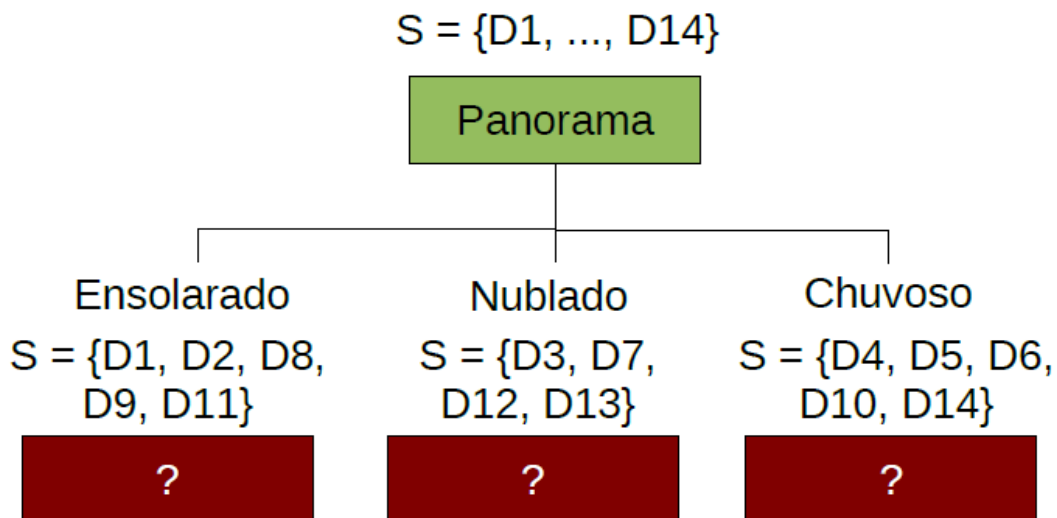
- Atributo com maior ganho é selecionado para ser raiz da árvore de decisão
  - É o que mais reduz o nível de incerteza!
  - Panorama é escolhido
  - Criamos nós filhos a partir da raiz de acordo com os possíveis valores assumidos pelo atributo Panorama



# AD do problema “jogar tênis”

80

- Proceder da mesma maneira para os demais ramos que surgem a partir da raiz
- Em cada ramo consideramos somente os exemplos nele contidos
  - ▣ Desde que haja divergência entre as classes de saída



# ○ problema “jogar tênis”

81

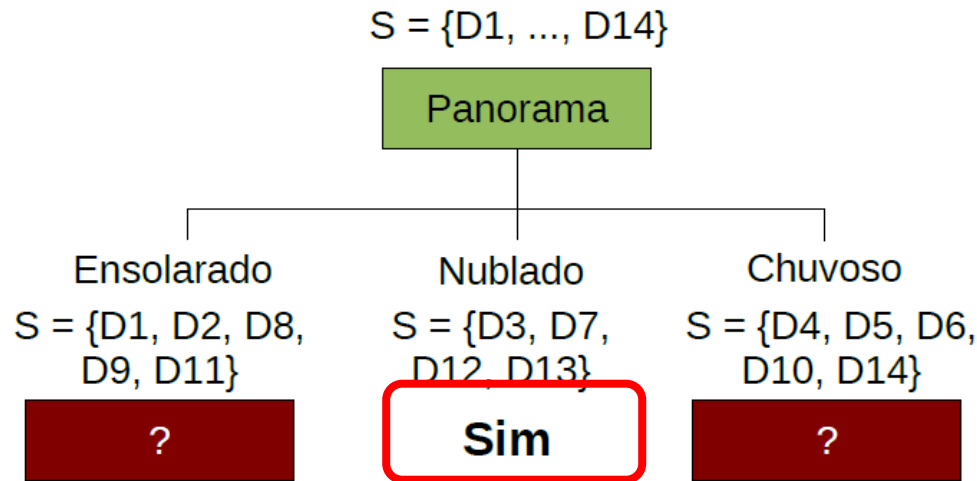
Análise do Nublado

INSTÂNCIAS					CLASSE
Dia	Perspectiva	Temperatura	Umidade	Vento	JogarTênis
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Moderada	Alta	Fraco	Sim
D5	Chuvoso	Fresca	Normal	Fraco	Sim
D6	Chuvoso	Fresca	Normal	Forte	Não
D7	Nublado	Fresca	Normal	Forte	Sim
D8	Ensolarado	Moderada	Alta	Fraco	Não
D9	Ensolarado	Fresca	Normal	Fraco	Sim
D10	Chuvoso	Moderada	Normal	Fraco	Sim
D11	Ensolarado	Moderada	Normal	Forte	Sim
D12	Nublado	Moderada	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Moderada	Alta	Forte	Não

# AD do problema “jogar tênis”

82

- Um dos ramos não tem divergência entre as classes de saída, ou seja, Entropia é igual a zero



- Atributos existentes incorporados acima de determinado nó não entram na avaliação de Ganho de Informação desse nó
  - ▣ Neste caso dois novos nós serão criados
  - ▣ O atributo panorama não será mais avaliado

# ○ problema “jogar tênis”

83

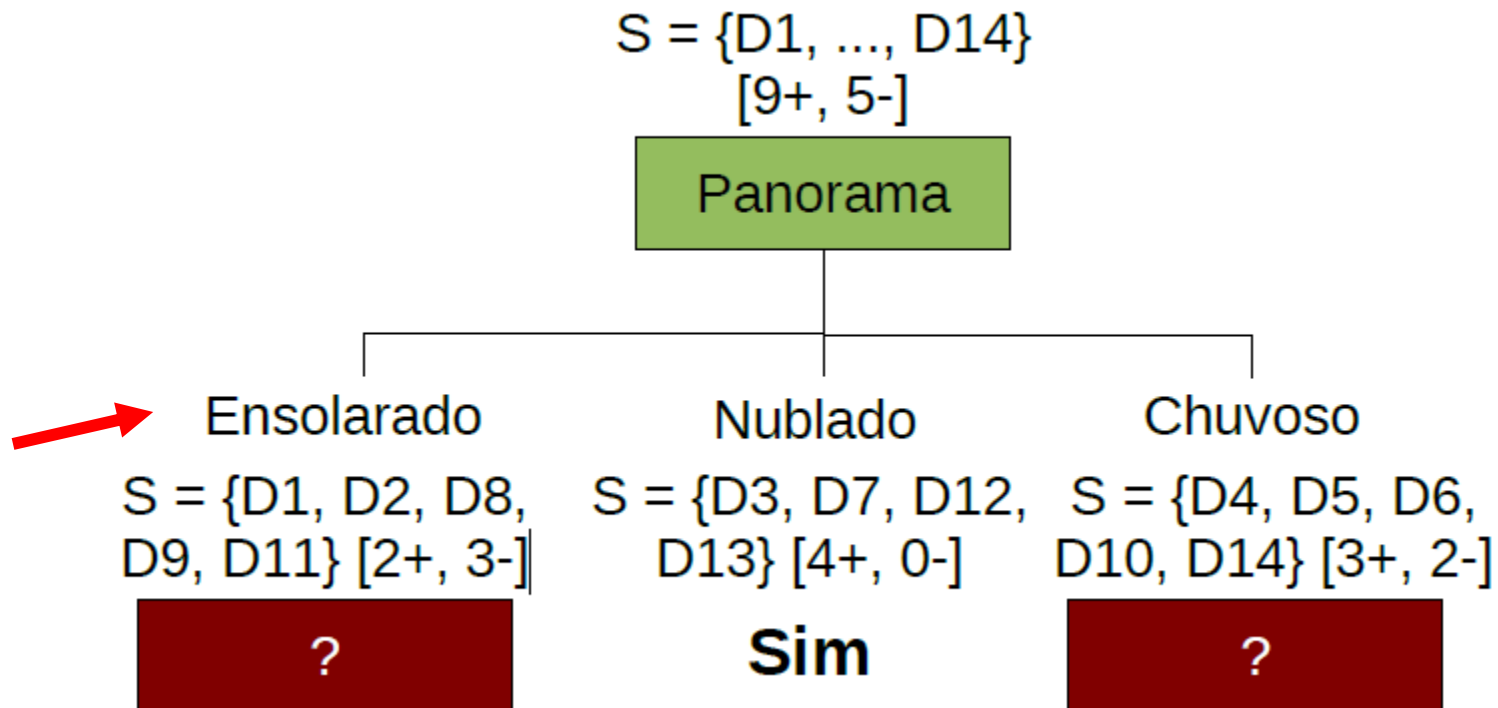
Análise do Ensolarado

INSTÂNCIAS					CLASSE
Dia	Perspectiva	Temperatura	Umidade	Vento	JogarTênis
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Moderada	Alta	Fraco	Sim
D5	Chuvoso	Fresca	Normal	Fraco	Sim
D6	Chuvoso	Fresca	Normal	Forte	Não
D7	Nublado	Fresca	Normal	Forte	Sim
D8	Ensolarado	Moderada	Alta	Fraco	Não
D9	Ensolarado	Fresca	Normal	Fraco	Sim
D10	Chuvoso	Moderada	Normal	Fraco	Sim
D11	Ensolarado	Moderada	Normal	Forte	Sim
D12	Nublado	Moderada	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Moderada	Alta	Forte	Não

[2+, 3-]

# AD do problema “jogar tênis”

84



# AD do problema “jogar tênis”

85

## □ Ganho de Informação para o ramo Ensolarado

### ▣ Calcula-se a Entropia para $E(S = \text{Ensolarado})$

$$E(S = \text{Ensolarado}) = -\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5} = \underline{0.97}$$

### ▣ Escolher a raiz (cálculo de ganho de informação)

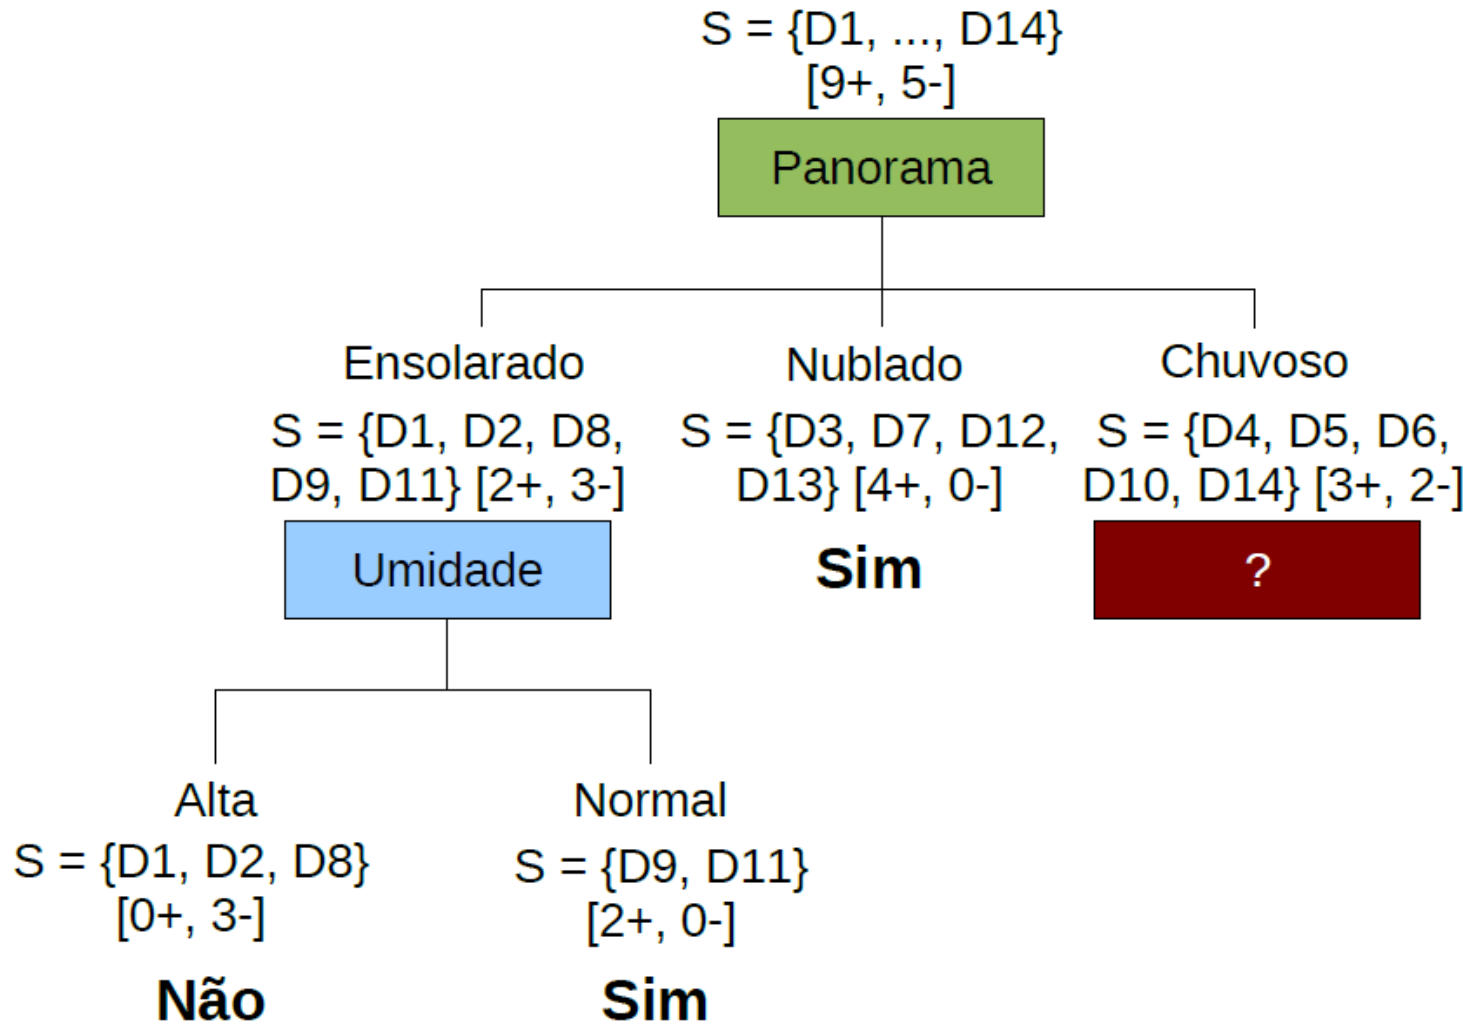
$$\text{GI}(S, \text{Umidade}) = 0.97 - \frac{3}{5}0.0 - \frac{2}{5}0.0 = \boxed{0.97}$$

$$\text{GI}(S, \text{Temperatura}) = 0.97 - \frac{2}{5}0.0 - \frac{2}{5}1.0 = 0.57$$

$$\text{GI}(S, \text{Vento}) = 0.97 - \frac{2}{5}1.0 - \frac{3}{5}0.918 = 0.019$$

# AD do problema “jogar tênis”

86



# Umidade alta

87

Análise do Ensolarado

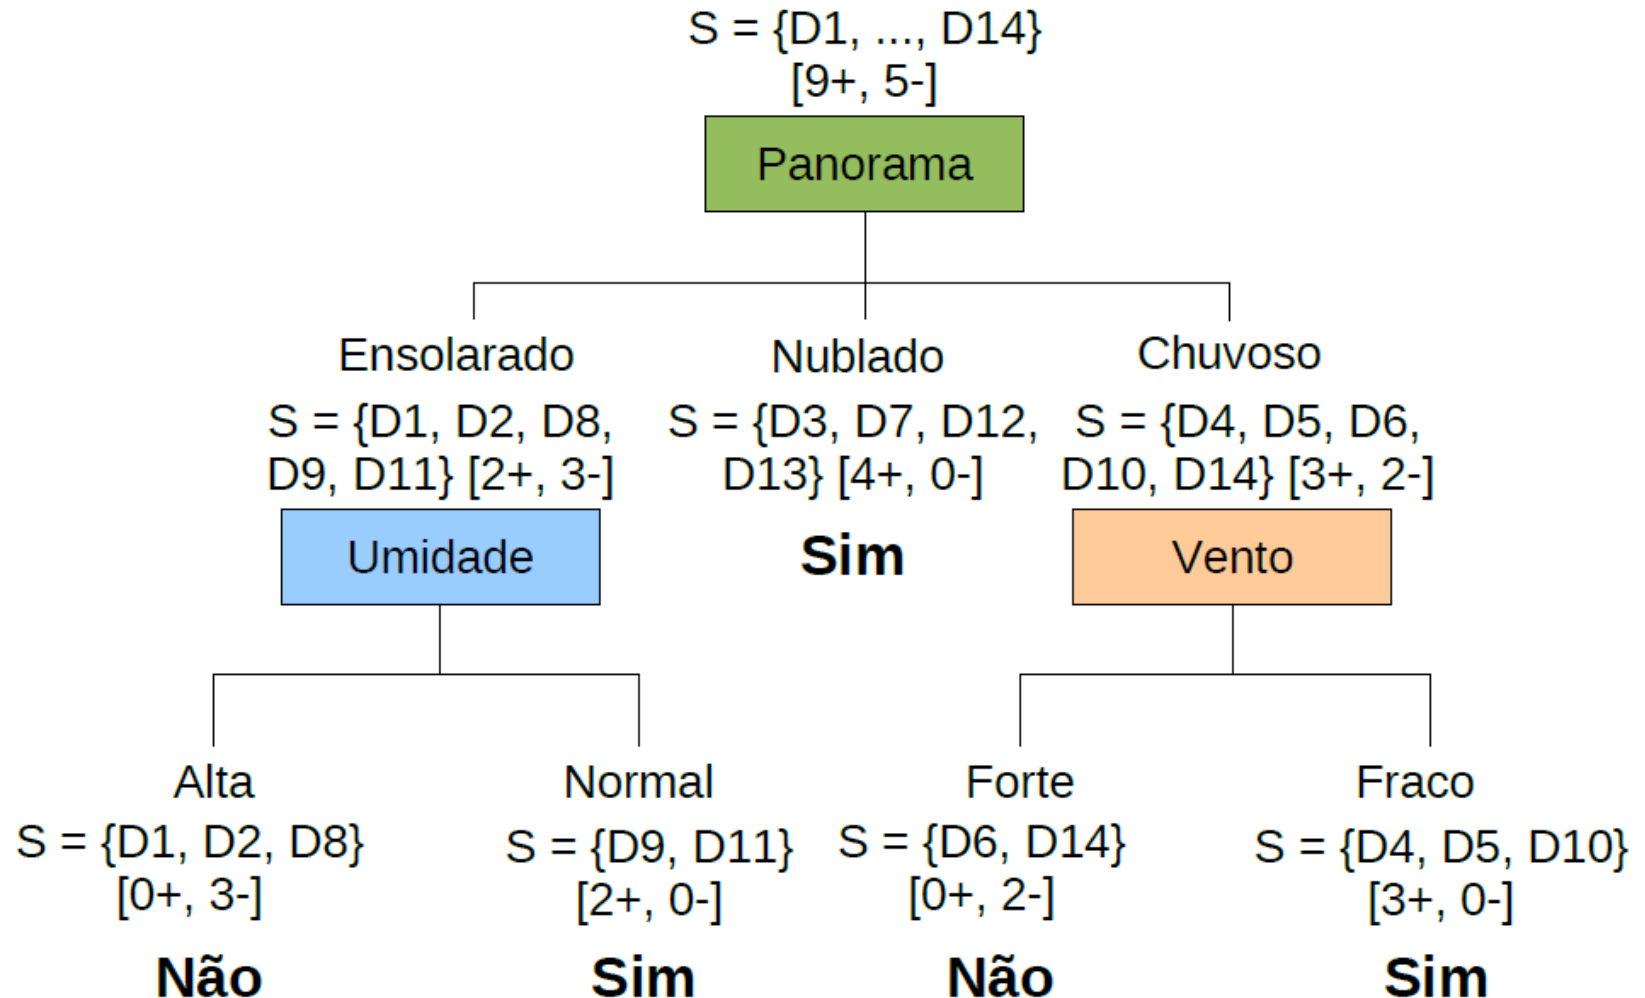
INSTÂNCIAS					CLASSE
Dia	Perspectiva	Temperatura	Umidade	Vento	JogarTênis
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Moderada	Alta	Fraco	Sim
D5	Chuvoso	Fresca	Normal	Fraco	Sim
D6	Chuvoso	Fresca	Normal	Forte	Não
D7	Nublado	Fresca	Normal	Forte	Sim
D8	Ensolarado	Moderada	Alta	Fraco	Não
D9	Ensolarado	Fresca	Normal	Fraco	Sim
D10	Chuvoso	Moderada	Normal	Fraco	Sim
D11	Ensolarado	Moderada	Normal	Forte	Sim
D12	Nublado	Moderada	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Moderada	Alta	Forte	Não

[2+, 3-]



# AD do problema “jogar tênis”

88



# Umidade baixa

89

Análise do Ensolarado

INSTÂNCIAS					CLASSE
Dia	Perspectiva	Temperatura	Umidade	Vento	JogarTênis
D1	Ensolarado	Quente	Alta	Fraco	Não
D2	Ensolarado	Quente	Alta	Forte	Não
D3	Nublado	Quente	Alta	Fraco	Sim
D4	Chuvoso	Moderada	Alta	Fraco	Sim
D5	Chuvoso	Fresca	Normal	Fraco	Sim
D6	Chuvoso	Fresca	Normal	Forte	Não
D7	Nublado	Fresca	Normal	Forte	Sim
D8	Ensolarado	Moderada	Alta	Fraco	Não
D9	Ensolarado	Fresca	Normal	Fraco	Sim
D10	Chuvoso	Moderada	Normal	Fraco	Sim
D11	Ensolarado	Moderada	Normal	Forte	Sim
D12	Nublado	Moderada	Alta	Forte	Sim
D13	Nublado	Quente	Normal	Fraco	Sim
D14	Chuvoso	Moderada	Alta	Forte	Não

[2+, 3-]

# Outros critérios

90

- Há vários outros critérios que podem ser usados para selecionar atributos quando construindo uma árvore de decisão
- Nenhum critério é superior em todas as aplicações
- A eficácia de cada critério depende dos dados sendo minerados

# Vantagens e desvantagens da AD

91

- Pontos positivos
  - ▣ Modelo de simples interpretação
  - ▣ Possível variar precisão vs. concisão
  - ▣ Semelhança com sistemas especialistas
  
- Pontos negativos
  - ▣ Estrutura (ordem) da árvore depende dos dados
  - ▣ Em muitos casos a árvore pode ser extensa

# Síntese da aula

92

- Tarefa de classificação é relevante para várias aplicações e problemas de mineração de dados
- Há diversos métodos para a classificação
- Árvores de decisão é um método muito utilizado principalmente quando classes tem valores discretos
- Algoritmo recursivo de indução de árvores de decisão

# Fontes\*

98

- Alguns slides e imagens foram retirados do conteúdo em:
  - ▣ [http://www.lac.inpe.br/~rafael.santos/Docs/ELAC/2012/Elac01\\_DM\\_Dia2.pdf](http://www.lac.inpe.br/~rafael.santos/Docs/ELAC/2012/Elac01_DM_Dia2.pdf)
  - ▣ Slides Prof. Rodrigo Fernandes de Mello (IME/USP)